Результати досліджень

Для здійснення аналізу методу контрольованої нейромережевої генерації психоосвітніх відповідей було проаналізовано такі метрики як пошук релевантлих документів, якість ранжування, ступінь семантичної відповідності.

MRR (Mean Reciprocal Rank) – це метрика, яка використовується для оцінювання якості ранжування результатів пошуку та визначає, наскільки високо у списку знайдених документів розташований перший релевантний результат. Суть цієї метрики полягає в тому, що система формує список із кількох найбільш релевантних документів (top-k), після чого аналізується позиція першого документа, який дійсно відповідає запиту користувача. Чим ближче цей документ знаходиться до початку списку, тим вищим є значення метрики, що свідчить про кращу якість роботи системи пошуку. На рисунку 3.16 показано результат цієї метрики.

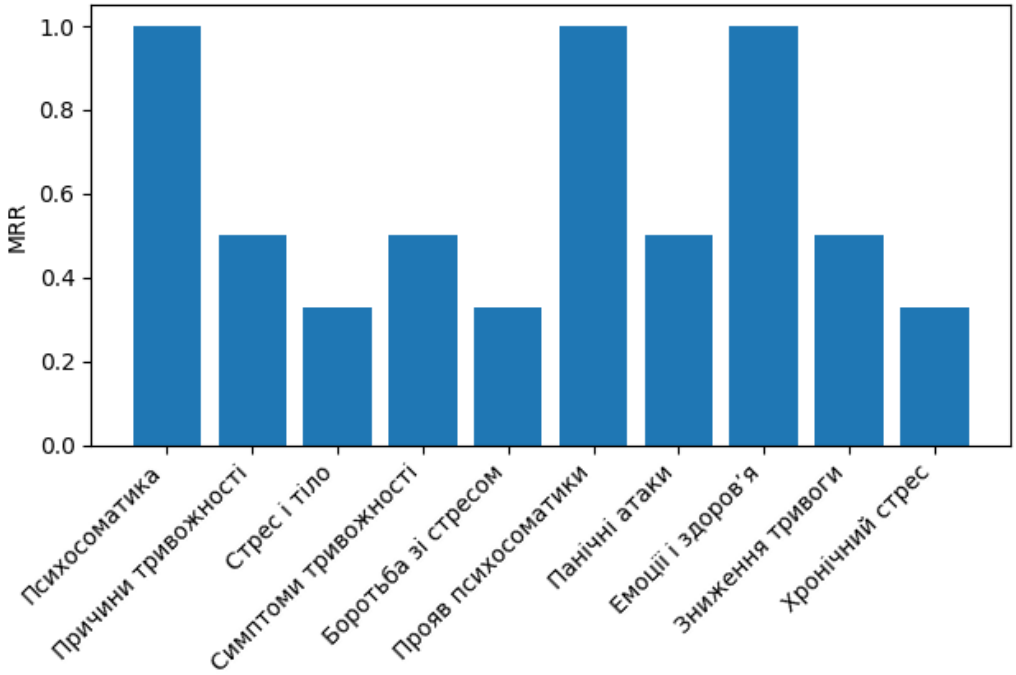

Рисунок 3.16 – Значення MRR для різних запитів

На діаграмі зображено значення метрики MRR для різних запитів, що відображає якість ранжування результатів пошуку. Видно, що для частини запитів система досягає максимального значення (1,0), тобто релевантний документ знаходиться на першій позиції, тоді як для інших значення нижчі (0,5 – 0,33), що вказує на його розташування на другій або третій позиціях.

Метрика Recall@K використовується для оцінювання здатності системи знаходити релевантні документи серед перших K результатів пошуку. Вона показує, яку частку релевантних документів було знайдено у верхній частині списку видачі, що дозволяє оцінити не лише факт їх наявності, а й ефективність раннього ранжування. У проведеному експерименті обрано значення K = 3, оскільки в реальних умовах користувач зазвичай орієнтується лише на перші кілька результатів видачі, а в рамках RAG-підходу саме ці документи формують контекст для генерації відповіді. Отримані значення Recall@3 варіюються від 0,5 до 1,0, що свідчить про те, що для частини запитів система знаходить усі релевантні документи вже серед перших трьох позицій, тоді як для інших лише частину з них. Середнє значення Recall@3 становить 0,7, що вказує на достатньо ефективну роботу системи пошуку, хоча в окремих випадках ранжування потребує покращення.

У межах дослідження було проаналізовано 100 запитів користувачів, що дозволило отримати узагальнену оцінку якості роботи системи. Для наочності представлення результатів із цієї вибірки випадковим чином було обрано 10 запитів, для яких детальні значення метрики наведено у таблиці 3.1. Такий підхід забезпечує репрезентативність результатів і водночас дозволяє продемонструвати поведінку системи на конкретних прикладах.

Таблиця 3.1 – Значення Recall@3 обраних випадкових запитів

Запит	Recall@3
Що таке психосоматика?	1,00
Причини тривожності	0,50
Як стрес впливає на тіло?	0,50
Симптоми тривожності	0,50
Методи боротьби зі стресом	0,50
Як проявляється психосоматика?	1,00
Що викликає панічні атаки?	1,00
Вплив емоцій на фізичне здоров’я	1,00
Як знизити рівень тривоги?	0,50
Фізичні наслідки хронічного стресу	0,50

З метою оцінки стійкості моделі до запитів, що не належать до предметної області, було сформовано набір із п’яти нерелевантних запитів. Результати представлено в таблиці 3.3.

Таблиця 3.2 – Значення Recall@3 для найгірших запитів

Запит	Recall@3
Як варити борщ?	0
Причини несправності літака	0
Найкращі міста для подорожей	0
Як створити книжку	0
Чому птахи відлітають у теплі краї	0

У процесі оцінювання якості роботи retrieval-компонента додатково було використано показник середньої семантичної схожості (cosine similarity) між векторним представленням запиту та знайденими документами. Дана величина відображає ступінь близькості текстів у векторному просторі та дозволяє оцінити, наскільки релевантні документи не лише присутні у вибірці, але й семантично відповідають запиту. За результатами експерименту середнє значення similarity для top-3 документів становить 0,474, що свідчить про помірно високий рівень семантичної відповідності. При цьому для запитів, пов'язаних із психосоматикою, значення досягають 0,533–0,577, що корелює з високими показниками Recall та MRR, тоді як для більш узагальнених або варіативних запитів, таких як «Як знизити рівень тривоги?», спостерігається зниження similarity до 0,381, що вказує на складність точного підбору релевантних фрагментів. Отримані результати підтверджують ефективність використання векторних представлень тексту, водночас демонструючи залежність якості пошуку від специфіки формулювання запиту. На рисунку 3.17 показано результат цієї метрики.

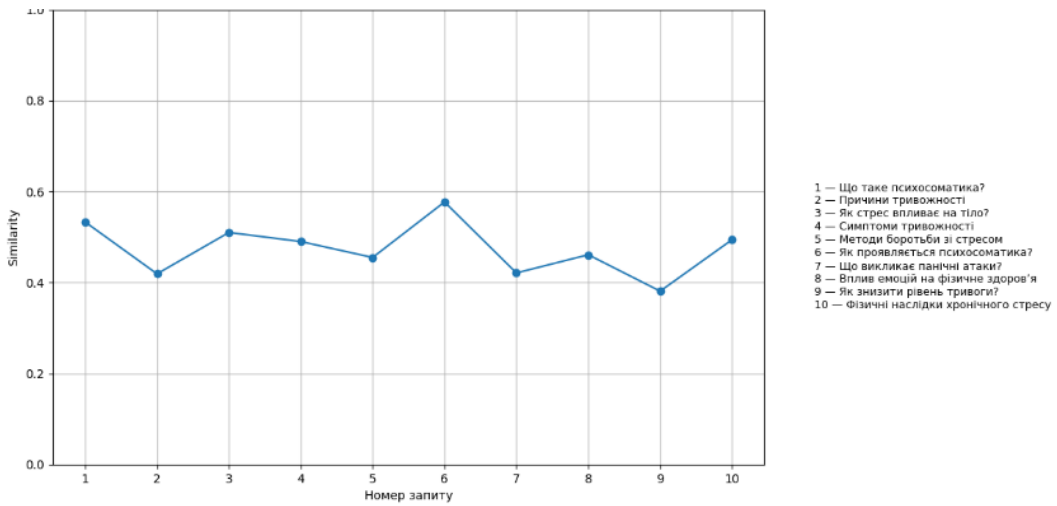

Рисунок 3.17 – Динаміка значень cosine similarity для різних запитів

Отримані значення метрик свідчать про коректність роботи програмного прототипу.

На основі розробленого програмного рішення здійснено тестування програмного продукту та проведено дослідження ефективності його функціонування. Зазначений етап дозволяє підтвердити якість розробки програмного продукту та є необхідним для своєчасного виявлення і корекції можливих недоліків.

Для тестування було використано юніт тести та тест кейси. На рисунку 3.10 показано успішно проходження юніт тесту з перевірки коректність логіки прийняття рішення щодо дозволу або заборони використання текстових матеріалів на основі відповіді мовної моделі, яка виконує тематичну валідацію.

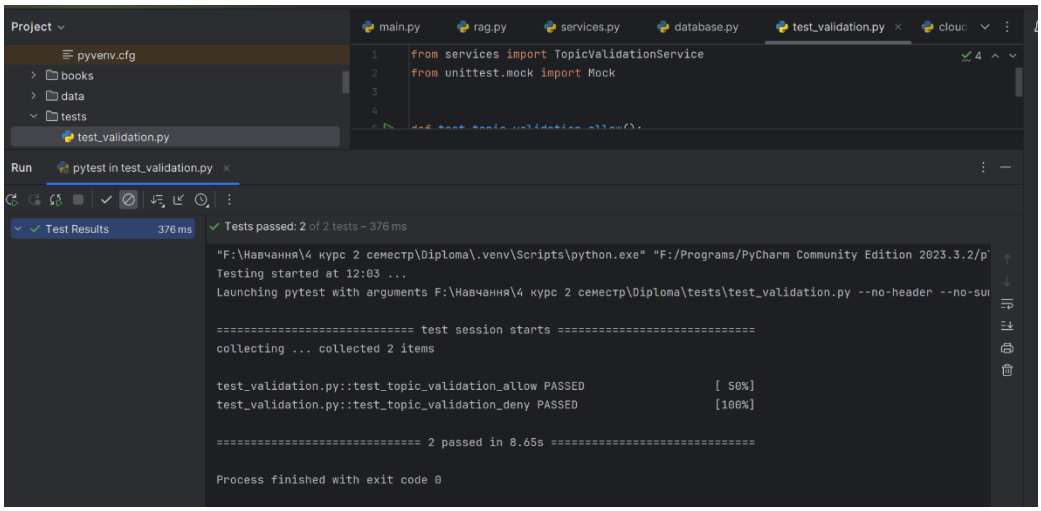

Рисунок 3.18 – Успішне проходження юніт тесту

Також було проведено дослідження ефективності відповідей чатботу. Для цього було сформовано 10 різних користувацьких запитів, на які система надала відповіді. Кожну відповідь було оцінено з точки зору відповідності запиту та коректності наданої інформації. Оцінювання здійснювалося за допомогою окремого модуля, який використовує велику мовну модель у ролі незалежного експерта. Модель аналізує запит і згенеровану відповідь, після чого формує оцінку за шкалою від 1 до 10, враховуючи такі критерії, як релевантність відповіді, її змістовна повнота, логічна узгодженість та відповідність обмеженням психоосвітнього домену. Результати оцінювання наведено в таблиці 3.3.

Таблиця 3.3 – Результати оцінювання ефективності відповідей чатботу

Номер відповіді	Оцінка ефективності	Номер запиту	Оцінка ефективності
Відповідь 1	7/10	Відповідь 6	8/10
Відповідь 2	6/10	Відповідь 7	8/10
Відповідь 3	7/10	Відповідь 8	8/10
Відповідь 4	8/10	Відповідь 9	8/10
Відповідь 5	7/10	Відповідь 10	8/10

Отже, було проведено тестування та дослідження якості програмного продукту, що підтвердило коректність його роботи та ефективність отриманих результатів.